

1_Empirical_Risk_Minimization

문제 정의

- 일반적으로 인공지능 모델의 학습과정에서는 손실 함수를 정의하고 이를 최소화하는 매개변수를 구하는 것을 목표로 한다. 이러한 매개변수를 추정하기 위해 여러 기법이 사용되는데, 대표적인 예시로는 **MLE(Maximum Likelihood Estimation)**, **MAP(Maximum A Posterior)**가 있다. **Empirical Risk Minimization**은 MLE를 일반화하여 표현한 식으로, 손실 함수가 어떤 형태이든 적용할 수 있는 방법이다. ERM은 기본적으로 N개의 입력 데이터에 해당하는 Y를 추정하여 얻은 Loss들의 평균값을 말한다. 이를 분류 문제에 적용하면 N개의 분류 문제 중 제대로 분류하지 못한 것의 비율(Misclassification Rate)을 경험적 위험(Empirical Risk)으로 계산하여 이를 최소화하는 방식으로 작용하여 매개변수를 추정한다. ERM은 이처럼 한정된 훈련 데이터에서 경험적으로 추정된 데이터 생성 분포를 기반으로 전체 데이터 생성 분포에 근접한 매개변수를 추정하기 위해 제안되었다. 이를 통해 학습되지 않은 새로운 데이터에 대해서도 일반화 성능을 향상시키는 것을 목표로 한다.

해당 문제에 대한 일반적인 접근

- ERM의 경험적 위험은 훈련 Dataset N개에 대한 손실 함수의 평균으로 다음과 같은 수식으로 정의된다.
 $R_{emp}(\theta) = \frac{1}{N} \sum_{n=1}^N l(y_n, \theta; x_n)$. 일반적으로 매개변수를 추정하기 위해서는 경사하강법과 같은 최적화 알고리즘을 적용하여 매개변수를 업데이트 한다. 이 과정에서 경험적 위험에 대한 정보를 반영하기 위해 그라디언트에 경험적 위험을 곱하여 이를 손실 함수에 다음과 같은 수식처럼 반영한다. $\theta \leftarrow \theta - \eta \nabla \theta R_{emp}(\theta)$. 이 과정을 반복하며 별도의 검증 데이터셋을 사용하여 추정된 매개변수를 가진 모델의 성능을 평가한다.

일반적인 접근법의 제한 사항

- ERM은 한정된 훈련 데이터의 분포에 대해 정의된 손실 함수를 기반으로 하기에 **과적합** 문제가 발생할 가능성이 있다. 그리고 대부분의 경우 **경험적 데이터에 따른 분포는 실제 분포와 동일하지 않다**. 이로 인해 모델이 학습하지 않은 데이터에 대해 잘못 예측할 수 있는데 이는 **일반화 성능이 낮다**는 것을 의미한다. 또한, 대부분의 최적화 기법이 경사 하강법을 기반으로 하기에 **손실 함수의 기울기가 0이거나 미분이 불가능하다면 이를 사용할 수 없다**. 대표적인 예로 **0-1 Loss**가 있다. 이는 모델의 출력이 실제값과 같으면 0, 다르면 1을 출력하는데 이러한 손실 함수는 대부분의 점에서 기울기가 0이기 때문에, **훈련하는 모델의 성능을 평가할 수는 있어도 어느 방향으로 가중치를 수정해야 경험적 위험을 줄일 수 있는지는 알기 어렵다**.

제한 사항에 대한 해결 방안

- 과적합의 경우, **정규화**를 통해 해결할 수 있다. 먼저 모델의 **복잡도에 대한 페널티**를 손실 함수에 추가하는 방식이 있다. 그 방식으로는 매개변수 벡터의 절대값의 합에 비례하는 페널티를 추가하여 일부 매개변수의 값을 작게 만들어 모델의 복잡성을 낮추는 **L1 정규화**, 그리고 매개변수 벡터의 제곱의 합에 비례하는 페널티를 추가하여 모델의 매개변수 값이 상대적으로 작게 유지되도록 하는 **L2 정규화**가 있다. 또다른 방식으로는 **검증 데이터셋**을 사용하는 방법이 있다. 그 중에서 **교차 검증 기법**의 경우, 모델을 학습하는 과정에서 **데이터를 여러 개로 나누고 이 중 일부를 훈련에 그리고 나머지를 검증으로 사용하는 것이다**. 이를 통해 각기 다른 모델들을 여러 개 학습하여 평균, 최솟값 등의 기법으로 검증 데이터에 가장 높은 성능을 보이는 모델을 선택한다. 학습 과정에서는 이른 학습 중단 기법(**Early Stopping**)을 통해 정규화를 할 수 있다. 이는 **훈련 과정에서 검증 데이터셋의 성능이 더 이상 개선되지 않을 때, 훈련을 멈추는 기법으로, 너무 많은 훈련 Epoch로 발생할 수 있는 과적합을 방지하는데 도움이 될 수 있다**. 마지막으로 학습 데이터에 무작위성의 변화를 추가하는 **데이터 증강 기법**을 이용하여 데이터의 수를 늘려 정규화할 수 있는 방법이 있다. 이처럼 모델의 매개변수를 줄이거나 데이터의 수를 늘리면 효과적으로 정규화를 할 수 있다.
- 손실 함수의 기울기가 0이 되는 문제의 경우 **대체 손실 함수 기법(Surrogate Loss)**을 통해 해결할 수 있다. 이는 0-1 Loss 처럼 Gradient가 0이 되는 부분이 많은 경우, 이를 **대신할 수 있는 손실 함수를 정의하여 이를**

대신 최소값으로 최적화시키는 기법이다. 이러한 대체 손실 함수의 예시로는 실제 레이블과 예측 확률 간의 차이를 로그 함수로 측정하는 **Logistic Loss**, SVM에서 마진 오류를 최소화하는 역할을 하는 **Hinge Loss** 등을 사용한다.